LABORATORIUM 3

Stosowanie klasyfikatorów uczenia maszynowego

Zestawy danych

https://data.gov/ to portal otwartych danych rządu Stanów Zjednoczonych.

https://www.ncdc.noaa.gov/cag/ - zapewnia portal klimatyczny NOAA

https://www.esrl.noaa.gov/psd/data/timeseries/ - Portal badań Ziemi administracja laboratoriów (ESRL, Earth System Research Laboratory) NOAA dostarcza miesięczne i sezonowe z danymi klimatycznymi.

https://www.quandl.com/search - Quandl udostępnia setki bezpłatnych szeregów czasowych z danymi finansowymi, a także zestawy danych z płatnym dostępem.

https://datamarket.com/data/list/?q=provider:tsdl - biblioteka danych TSDL (biblioteka danych szeregów czasowych) zawiera linki do setek tymczasowych zbiorów danych rzędy w wielu obszarach przemysłowych.

http://archive.ics.uci.edu/ml/datasets.html - repozytorium uczenia maszynowego Uniwersytetu Kalifornijskiego w Irvine (UCI) zawiera dziesiątki zestawów danych szeregów czasowych z różnych obszary.

ZADANIE

- 1. Należy napisać program (za pomocą biblioteki **scikit-learn**), który realizuje następne metody(algorytmy):
 - regresji logistycznej
 - maszyny wektorów nośnych
 - jądra SVM
 - Uczenia drzew decyzyjnych
 - Algorytm k-najbliższych sąsiadów

Proszę o wybranie jednego zestawu danych (dowolnego, które Państwa interesują) i sprawdzenie na nim algorytmów klasyfikacji.

Na ocenę 3 proszę o zaprogramowanie dowolnego (jednego!) algorytmu,

na 4 dowolne dwa algorytmy,

na 5 dowolnych trzech algorytmów

Zrób podsumowanie: który z algorytmów uzyskał lepsze wyniki w klasyfikacji, dlaczego